Matriz de consistencia

Mejora recursiva de harnesses agénticos con modelos de pesos abiertos

Problema. Construir agentes exige ajustar instrucciones, roles y coordinación por ensayo y error. Se estudia su mejora automática y la adaptación de sus instrucciones de mejora.

Decisión correcta: coinciden acción, deuda, número de pagos e importe de cuota con la referencia del escenario. La acción será preguntar si falta la capacidad de pago; ofrecer la mayor deuda viable; aceptar solo el plan consentido; o detenerse ante rechazo o falta de un plan viable.
Restricciones críticas: formato y campos válidos; deuda y plan autorizados, con cuota calculada sin descuentos; cuota dentro de la capacidad declarada; ninguna oferta ni aceptación ante rechazo explícito; aceptación solo del plan consentido; sin datos de un plan cuando se pregunta o se detiene.

Nivel	Objetivo	Hipótesis	Variables	Indicadores y criterios
OG	Lograr que un sistema con modelos de pesos abiertos construya y mejore sus roles, prompts y workflows para resolver correctamente al menos 80% de los escenarios de cobranzas simuladas: acción, deuda, pagos y cuota correctos, sin infringir las reglas del caso ni editar manualmente el ciclo.	**HG:** el sistema alcanza al menos 80% de respuestas correctas y ninguna infracción observada en test, sin edición humana durante el ciclo y con modelo y evaluación fijos.	**VI:** régimen Z. **VD:** q, v, N_h. **Complementarias:** T_{meta}, r_{uso}, M_h.	• **Resultado en test:** $q_{test} \geq 0.80$ y $v_{test}=0$. • **Sin edición humana:** $N_h=0$. Comparte el criterio de OE1; OE2 contrasta la ventaja de adaptar.
OE1	Obtener un sistema que construya, pruebe y mejore su configuración hasta responder con acción, deuda, pagos y cuota correctos en al menos 80% de los escenarios de test, sin infringir las reglas del caso ni edición humana durante el ciclo, y que reutilice instrucciones de mejora actualizadas.	**HE1:** el sistema alcanza $q_{test} \geq 0.80$, $v_{test}=0$ y $N_h=0$; en B2, usa al menos una actualización de instrucciones en una propuesta posterior.	**Condición:** Z=1. **VD:** q, v, N_h. **Técnicas:** N_{uso}, V_{prot}, ρ_{traza}.	• $q_{test} \geq 0.80$ y $v_{test}=0$. • $N_h=0$. • **Actualización usada:** $N_{uso} \geq 1$. • **Controles intactos:** $V_{prot}=0$. • **Trazabilidad:** $\rho_{traza}=1$. Informar proporción de búsquedas que cumple e incertidumbre.
OE2	Lograr que adaptar las instrucciones de mejora aumente al menos cinco puntos porcentuales la proporción de respuestas con acción, deuda, pagos y cuota correctos, sin infringir las reglas del caso, frente a instrucciones fijas; sin aumentar infracciones y con igual modelo y tope de recursos.	**HE2:** B2 supera a B1 al menos cinco puntos en q de test, sin aumentar v, con el mismo tope de recursos e incluyendo el costo de adaptar instrucciones.	**VI:** Z=0 frente a Z=1. **VD:** q, v. **Contrastes:** Δ_q, Δ_v. **Complementarias:** T_{meta}, r_{uso}, M_h.	• **Ventaja observada:** $\Delta_q \geq 0.05$. • **Respaldo estadístico:** $L_{95}(\Delta_q)>0$. • **Sin aumento de infracciones:** $U_{95}(\Delta_v) \leq 0$. • Igual tope de recursos y condiciones emparejadas.

OG: objetivo general. **Comparación:** B1 cambia el harness con instrucciones de mejora fijas (Z=0). B2 también puede actualizar esas instrucciones (Z=1). Modelo, evaluación y presupuesto se mantienen iguales.

Lectura: q = respuestas correctas sin infracciones / respuestas evaluadas; v = respuestas con infracciones / respuestas evaluadas. N_h: intervenciones humanas; T_{meta}: tiempo hasta la meta; r_{uso}: tokens, llamadas y costo; M_h: minutos humanos. N_{uso}: actualizaciones reutilizadas; V_{prot}: cambios en partes protegidas; ρ_{traza}: propuestas reconstruibles / registradas.

Δ_q y Δ_v: diferencias medias B2 menos B1; L_{95} y U_{95}: límites inferior y superior del intervalo de confianza del 95%. Los valores medidos son estimaciones. **Umbrales propuestos, por fijar antes del contraste.** La búsqueda usa desarrollo/validación; test se reserva al final. El Test 1 revisa decisiones estructuradas, no conversaciones completas ni cumplimiento bancario real.