# Matriz de consistencia

## Mejora recursiva de harnesses agénticos con modelos de pesos abiertos

**Problema.** Construir agentes exige ajustar instrucciones, roles y coordinación por ensayo y error. Se busca que el sistema haga esos ajustes y comprobar si conviene que también cambie su forma de proponer mejoras.

| Nivel | Objetivo | Hipótesis | Variables | Indicadores y criterios |
|---|---|---|---|---|
| **OG** | Lograr que un sistema de IA construya y mejore su configuración agéntica, mediante cambios en roles, system prompts y workflows, hasta alcanzar una calidad definida con intervención humana acotada, usando modelos de pesos abiertos en escenarios simulados de cobranzas. | **HG:** el sistema puede obtener una configuración que alcance la calidad y el cumplimiento requeridos sin ediciones humanas durante el ciclo de mejora, manteniendo fijos los pesos del modelo y la evaluación. | **VI:** régimen Z. **VD:** q, v, $N_h$. **Complementarias:** $T_{meta}$, $r_{uso}$, $M_h$. | • **Calidad final:** $q_{test} \geq 0.80$, al menos 80% de éxito válido. • **Cumplimiento:** $v_{test}=0$, ninguna infracción crítica observada. • **Autonomía:** $N_h=0$, sin edición humana dentro del ciclo. Comparte el criterio de OE1; la ventaja de adaptar se contrasta en OE2. |
| **OE1** | Obtener un sistema que construya, pruebe y mejore su configuración hasta alcanzar la calidad requerida, sin edición humana durante el ciclo, y que pueda actualizar y reutilizar sus instrucciones de mejora. | **HE1:** el sistema alcanza la calidad y el cumplimiento requeridos sin intervención durante el ciclo; en B2, utiliza al menos una actualización de sus instrucciones para proponer una versión posterior. | **Condición:** Z=1 para verificar adaptación. **VD:** q, v, $N_h$. **Comprobación técnica:** $N_{uso}$, $V_{prot}$, $\rho_{traza}$. | • **Resultado:** $q_{test} \geq 0.80$ y $v_{test}=0$. • **Autonomía:** $N_h=0$. • **Adaptación utilizada:** $N_{uso} \geq 1$. • **Controles intactos:** $V_{prot}=0$. • **Trazabilidad completa:** $\rho_{traza}=1$. Informar qué proporción de búsquedas cumple estos criterios y con qué incertidumbre. |
| **OE2** | Lograr que adaptar las instrucciones de mejora aumente el éxito válido frente a mantenerlas fijas, sin aumentar los incumplimientos, con el mismo modelo y tope de recursos. | **HE2:** B2 supera a B1 en éxito válido en escenarios reservados para la prueba final, sin aumentar la tasa de infracciones críticas y contabilizando el costo de adaptar las instrucciones. | **VI:** Z=0 frente a Z=1. **VD principales:** q, v. **Contrastes:** $\Delta_q$, $\Delta_v$. **Complementarias:** $T_{meta}$, $r_{uso}$, $M_h$. | • **Ventaja observada:** $\Delta_q \geq 0.05$, al menos 5 puntos porcentuales más de éxito válido. • **Ventaja respaldada:** $L_{95}(\Delta_q)>0$, el intervalo de la diferencia de calidad queda por encima de cero. • **Sin aumento de infracciones:** $U_{95}(\Delta_v) \leq 0$, el intervalo descarta un aumento según el criterio propuesto. • **Comparación equivalente:** mismo tope de recursos y condiciones emparejadas. |

**OG:** objetivo general. **Comparación:** B1 cambia el harness con instrucciones de mejora fijas (Z=0). B2 también puede actualizar esas instrucciones (Z=1). Modelo, evaluación y presupuesto se mantienen iguales.

**Lectura:** q: éxito válido; v: incumplimientos; $N_h$: intervenciones humanas; $T_{meta}$: tiempo hasta la meta; $r_{uso}$: tokens, llamadas y costo; $M_h$: minutos humanos. $N_{uso}$: actualizaciones reutilizadas; $V_{prot}$: cambios en partes protegidas; $\rho_{traza}$: propuestas reconstruibles / registradas.

$\Delta_q$ y $\Delta_v$: diferencias medias B2 menos B1; $L_{95}$ y $U_{95}$: límites inferior y superior del intervalo de confianza del 95%. Los valores medidos son estimaciones. **Los umbrales se revisarán en factibilidad y se fijarán antes del contraste.**